

Proyecto 1

Cristian Josue Herrera

2026-05-16

```
## Warning: package 'ggplot2' was built under R version 4.4.3

## # A tibble: 53,940 x 10
##   carat cut      color clarity depth table price      x      y      z
##   <dbl> <ord>    <ord> <ord>    <dbl> <dbl> <int> <dbl> <dbl> <dbl>
## 1  0.23 Ideal      E      SI2     61.5    55    326  3.95  3.98  2.43
## 2  0.21 Premium   E      SI1     59.8    61    326  3.89  3.84  2.31
## 3  0.23 Good      E      VS1     56.9    65    327  4.05  4.07  2.31
## 4  0.29 Premium   I      VS2     62.4    58    334  4.2   4.23  2.63
## 5  0.31 Good      J      SI2     63.3    58    335  4.34  4.35  2.75
## 6  0.24 Very Good J      VVS2     62.8    57    336  3.94  3.96  2.48
## 7  0.24 Very Good I      VVS1     62.3    57    336  3.95  3.98  2.47
## 8  0.26 Very Good H      SI1     61.9    55    337  4.07  4.11  2.53
## 9  0.22 Fair      E      VS2     65.1    61    337  3.87  3.78  2.49
## 10 0.23 Very Good H      VS1     59.4    61    338  4     4.05  2.39
## # i 53,930 more rows

##
## Adjuntando el paquete: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

El equipo comercial de una tienda de diamantes sospecha que algunos diamantes tienen precios inusualmente altos en relación con el peso. Por lo tanto, el presente análisis busca identificar estos productos de alto costo, calcular indicadores de precios y resumir la información por la calidad de corte.

Para este análisis utilizamos la base de datos *diamonds*, incluida en el paquete *ggplot2*. Esta base contiene información sobre diamantes y algunas de sus características físicas y comerciales. Algunas de sus columnas principales son:

- **price:** precios del diamante en dolares estadounidense.
- **carat:** peso del diamante en quilates, donde un mayor valor indica un diamante mas grande.
- **cut:** calidad del corte, una variable categórica de jerarquía (*Fair*, *Good*, *Very Good*, *Premium*, *Ideal*).

- **color:** color del diamante.
- **clarity:** claridad del diamante, describe las imperfecciones de la piedra.

Al analizar el valor de un diamante, el precio total no es una métrica suficiente para realizar comparaciones justas entre distintas joyas. Esto se debe a que el precio no aumenta de manera lineal con el peso, un diamante puede tener un precio alto simplemente porque es muy pesado y no necesariamente por su calidad óptica (corte, color, claridad) sea superior.

Por eso vamos a construir una variable que mide el precio del diamante en relación con su peso. Además crearemos una nueva variable para clasificar si los precios son muy altos o no; utilizaremos la clasificación por cuantiles.

```
diamantes <- diamonds %>%
  mutate(precio_por_quilate = price / carat)

#Clasificación de precios
precio_muy_alto <- quantile(diamantes$precio_por_quilate, probs = 0.95)
precio_alto <- quantile(diamantes$precio_por_quilate, probs = 0.75)
precio_medio <- quantile(diamantes$precio_por_quilate, probs = 0.5)

clasificacion <- diamantes %>%
  mutate(clasificacion_precio = case_when(
    precio_por_quilate >= precio_muy_alto ~ "Muy Alto",
    precio_por_quilate >= precio_alto ~ "Alto",
    precio_por_quilate >= precio_medio ~ "Medio",
    TRUE ~ "Bajo"
  ))
```

Veamos una inspección intermedia de la tabla:

```
clasificacion %>%
  select(price, carat, cut, precio_por_quilate, clasificacion_precio) %>%
  head(10)
```

```
## # A tibble: 10 x 5
##   price carat cut          precio_por_quilate clasificacion_precio
##   <int> <dbl> <ord>          <dbl> <chr>
## 1  326  0.23 Ideal          1417. Bajo
## 2  326  0.21 Premium      1552. Bajo
## 3  327  0.23 Good         1422. Bajo
## 4  334  0.29 Premium      1152. Bajo
## 5  335  0.31 Good         1081. Bajo
## 6  336  0.24 Very Good     1400. Bajo
## 7  336  0.24 Very Good     1400. Bajo
## 8  337  0.26 Very Good     1296. Bajo
## 9  337  0.22 Fair         1532. Bajo
## 10 338  0.23 Very Good     1470. Bajo
```

Ahora agrupamos los datos por la variable **cut**, para resumir la información.

```
resumen <- clasificacion %>%
  group_by(cut) %>%
```

```

summarise(
  precio_medio = mean(price),
  precio_medio_quilate = mean(precio_por_quilate),
  diamantes_muy_caros = sum(clasificacion_precio == "Muy Alto"),
  diamantes_caros = sum(clasificacion_precio == "Alto"),
  total = n()
) %>%
  arrange(desc(precio_medio_quilate))

knitr::kable(resumen,
  caption = "Resumen por Calidad de corte")

```

Table 1: Resumen por Calidad de corte

cut	precio_medio	precio_medio_quilate	diamantes_muy_caros	diamantes_caros	total
Premium	4584.258	4222.905	768	3271	13791
Very Good	3981.760	4014.128	579	2555	12082
Ideal	3457.542	3919.700	1186	3727	21551
Good	3928.864	3860.028	139	962	4906
Fair	4358.758	3767.256	25	273	1610

Al evaluar el precio total absoluto, el corte que representa mayor promedio es el **Premium**, seguido de cerca por el corte **Fair**.

Mientras que al ajustar el precio en relación al peso de la gema, se observa que el corte **Premium** sigue teniendo mayor promedio, pero en este caso es seguido por el corte **Very Good**.

```

cantidad_total <- resumen %>%
  select(diamantes_muy_caros, diamantes_caros) %>%
  summarise(
    total_diamantes_muy_caros = sum(diamantes_muy_caros),
    total_diamantes_caros = sum(diamantes_caros)
  )

cantidad_total

```

```

## # A tibble: 1 x 2
##   total_diamantes_muy_caros total_diamantes_caros
##               <int>               <int>
## 1                 2697                 10788

```

Dado que para la clasificación se ha realizado por percentiles, podemos observar que hay un total de 2697 diamantes están clasificados con un precio “Muy Caro”, y 10 788 diamantes están etiquetados como diamantes con precio “Caro”, de un total de 53 940 diamantes.

Además identificamos que el corte **Ideal** tiene la mayor cantidad de diamantes clasificado con un precio “Muy Caro”, seguido por el corte **Premium**, además en la clasificación de precio “Caro”, se tiene que los mismos corten tienen mayor cantidad de diamantes.

Sin embargo, esto podría deberse en gran medida que el ambos cortes tienen la mayor cantidad de diamantes; así que realizamos lo siguiente:

```

porcentajes <- resumen %>%
  select(cut, diamantes_muy_caros, diamantes_caros, total) %>%
  mutate(
    porcentaje_muy_caros = round((diamantes_muy_caros / total)*100, 2),
    porcentaje_caros = round((diamantes_caros / total)*100, 2)
  )

porcentajes <- porcentajes %>%
  group_by(cut) %>%
  select(porcentaje_muy_caros, porcentaje_caros) %>%
  arrange(desc(porcentaje_muy_caros))

```

Adding missing grouping variables: 'cut'

```
porcentajes
```

```

## # A tibble: 5 x 3
## # Groups:   cut [5]
##   cut      porcentaje_muy_caros porcentaje_caros
##   <ord>                <dbl>          <dbl>
## 1 Premium              5.57             23.7
## 2 Ideal                 5.5              17.3
## 3 Very Good            4.79             21.2
## 4 Good                 2.83             19.6
## 5 Fair                 1.55             17.0

```

Observamos que los cortes que tienen un precio “*Muy Caro*” porcentualmente siguen siendo los mismos, con muy poca diferencia entre ellos. Al observar porcentualmente los que están catalogados con precio “*Caro*”, el corte **Premium** es ahora el mas alto y es seguido por el corte **Very Good**.

Podemos concluir que, aunque en cantidad son muchos, son porcentualmente muy pocos los que están catalogados con precios “*Caros*” o “*Muy Caros*”.