

Proyecto 2

Cristian J. Herrera

Proyecto Unidad III

Auditoría automatizada de bases de datos para reportes empresariales

1. Contexto del problema

En una empresa de análisis de datos es común recibir varias bases de datos provenientes de distintas áreas: ventas, transporte, producción, inventarios o estudios técnicos.

Antes de hacer análisis avanzados, es necesario revisar la calidad de cada base de datos. Por ejemplo:

- identificar qué columnas son numéricas;
- detectar valores faltantes;
- calcular medidas resumen;
- revisar si hay columnas con poca variabilidad;
- encontrar posibles errores;
- comparar variables entre sí;
- generar reportes automáticos.

En este proyecto se construirá un sistema sencillo de auditoría de datos usando únicamente herramientas de iteración en R.

2. Bases de datos a utilizar

Usaremos bases de datos conocidas que vienen incluidas en R:

```
data(mtcars)
data(cars)
data(iris)
data(airquality)
```

Descripción breve de las bases

mtcars

Contiene información de automóviles, como consumo de combustible, peso, potencia y número de cilindros.

cars

Contiene información sobre velocidad y distancia de frenado de automóviles.

iris

Contiene mediciones de flores de tres especies distintas.

airquality

Contiene mediciones de calidad del aire en Nueva York, incluyendo ozono, radiación solar, viento y temperatura.

3. Objetivo general

Diseñar un sistema de auditoría automática que reciba varias bases de datos conocidas y genere reportes resumen usando herramientas de iteración en R.

4. Objetivos específicos

1. Crear funciones que identifiquen columnas numéricas y no numéricas.
2. Calcular medidas resumen para todas las columnas numéricas de varias bases de datos.
3. Detectar columnas con valores faltantes.
4. Aplicar funciones de manera segura usando manejo de errores.
5. Comparar pares de variables numéricas usando `map2()`.
6. Combinar reportes parciales usando `reduce()`.
7. Construir una tabla final que resuma el estado de cada base de datos.

5. Paquetes permitidos

Se recomienda cargar solo estos paquetes:

```
library(purrr)
library(dplyr)
library(tibble)
```

6. Estructura del proyecto

El proyecto se divide en seis partes.

Parte 1. Preparación de las bases de datos

Crea una lista llamada `bases` que contenga las 4 bases de datos.

Luego verifica:

1. Cuántas filas tiene cada base.
 2. Cuántas columnas tiene cada base.
 3. Qué clase tiene cada base.
-

Parte 2. Auditoría de tipos de variables

Para cada base de datos, identifica:

1. Cuántas columnas son numéricas.
 2. Cuántas columnas no son numéricas.
 3. Si todas las columnas son numéricas.
 4. Si existe al menos una columna no numérica.
-

Parte 3. Reporte automático de columnas numéricas

Para cada base de datos, conserva únicamente las columnas numéricas.

Después, para cada columna numérica calcula:

1. media;
2. mediana;
3. desviación estándar;
4. mínimo;
5. máximo;
6. rango.

Debes ignorar valores faltantes usando `na.rm = TRUE`.

Parte 4. Manejo de errores en auditoría

En la industria, las bases de datos no siempre vienen limpias. Algunas columnas pueden tener texto, valores faltantes o estructuras inesperadas.

Crea una función llamada `media_segura()` que intente calcular la media de una columna. Si no se puede calcular, debe devolver `NA`.

Luego aplícala a todas las columnas de cada base de datos, no solo a las numéricas.

Ejemplo conceptual

Si se aplica a `iris`, las columnas numéricas deben devolver una media, pero la columna `Species` debe devolver `NA`.

Parte 5. Comparación entre pares de variables

En algunos reportes empresariales se necesita comparar pares de variables.

Por ejemplo:

- en `cars`, comparar `dist` contra `speed`;
- en `iris`, comparar `Petal.Length` contra `Sepal.Length`;
- en `iris`, comparar `Petal.Width` contra `Sepal.Width`;
- en `mtcars`, comparar `hp` contra `mpg`;
- en `airquality`, comparar `Temp` contra `Wind`.

Crea una tabla llamada `comparaciones` con esta estructura:

```
comparaciones <- tibble(
  base = c("cars", "iris", "iris", "mtcars", "airquality"),
  variable_1 = c("dist", "Petal.Length", "Petal.Width", "hp", "Temp"),
  variable_2 = c("speed", "Sepal.Length", "Sepal.Width", "mpg", "Wind")
)
```

Para cada fila, calcula:

$$\text{diferencia de medias} = \bar{x}_1 - \bar{x}_2.$$

También calcula:

$$\text{razón de rangos} = \frac{\text{rango}(x_1)}{\text{rango}(x_2)}.$$

Parte 6. Reporte final usando `reduce()`

Al final debes construir un reporte general que combine varias tablas:

1. tabla de dimensiones de cada base;
2. tabla de tipos de variables;
3. tabla de cantidad de valores faltantes;
4. tabla resumen de columnas numéricas.

El objetivo es obtener una tabla final donde cada base tenga información general sobre su calidad.

7. Preguntas de interpretación

Responde brevemente:

1. ¿Qué base tiene más valores faltantes?
 2. ¿Qué base tiene más columnas numéricas?
 3. ¿Qué variable tiene el mayor rango en todo el proyecto?
 4. ¿Hay alguna base cuyas columnas sean todas numéricas?
 5. ¿Qué comparación tiene la mayor diferencia de medias?
-

8. Comentario final

Este proyecto simula una tarea real de la industria: construir un sistema básico de auditoría de datos.

Antes de aplicar modelos avanzados, las empresas necesitan saber:

- qué tipo de variables tienen;
- si existen valores faltantes;
- qué variables son numéricas;
- cuáles tienen rangos grandes;
- qué bases están listas para análisis;
- dónde hay posibles problemas de calidad.

Solución

Preparación de las bases de datos.

```
bases <- list(  
  mtcars = mtcars,  
  cars = cars,  
  iris = iris,  
  airquality = airquality)  
  
dimension <- tibble(  
  base = names(bases),  
  filas = map_int(bases, nrow),  
  columnas = map_int(bases, ncol),  
  clase = map_chr(bases, ~ class(.x)[1])  
)
```

dimension

```
## # A tibble: 4 x 4  
##   base      filas columnas clase  
##   <chr>    <int>    <int> <chr>  
## 1 mtcars      32      11 data.frame  
## 2 cars        50       2 data.frame  
## 3 iris       150       5 data.frame  
## 4 airquality  153       6 data.frame
```

Auditoria de tipos de variables

```
tipos_variables <- tibble(
  base = names(bases),
  col_num = map_int(
    bases, ~ sum(map_lgl(.x, is.numeric))),
  no_num = map_int(
    bases, ~ sum(!map_lgl(.x, is.numeric))),
  todas_numericas = map_lgl(bases, ~ every(.x, is.numeric)),
  alguna_no_numerica = map_lgl(bases, ~ some(.x, ~ !is.numeric(.x)))
)
```

tipos_variables

```
## # A tibble: 4 x 5
##   base      col_num no_num todas_numericas alguna_no_numerica
##   <chr>      <int>  <int> <lgl>          <lgl>
## 1 mtcars      11      0 TRUE          FALSE
## 2 cars        2      0 TRUE          FALSE
## 3 iris        4      1 FALSE          TRUE
## 4 airquality  6      0 TRUE          FALSE
```

Reporte automático de columnas numéricas

```
repor <- function(df, nombre_base) {
  df_num <- keep(df, is.numeric)

  map_dfr(names(df_num), function(nombre_col) {
    columna <- df_num[[nombre_col]]

    tibble(
      base = nombre_base,
      variable = nombre_col,
      media = mean(columna, na.rm = TRUE),
      mediana = median(columna, na.rm = TRUE),
      desv_std = sd(columna, na.rm = TRUE),
      minimo = min(columna, na.rm = TRUE),
      maximo = max(columna, na.rm = TRUE),
      rango = maximo - minimo
    )
  })
}
```

```
reportes <- map2(bases, names(bases), ~ repor(.x, .y))
```

reportes

```
## $mtcars
## # A tibble: 11 x 8
##   base      variable  media mediana desv_std minimo maximo  rango
```

```
##      <chr> <chr>      <dbl> <dbl>      <dbl> <dbl> <dbl> <dbl>
## 1 mtcars mpg      20.1   19.2      6.03  10.4   33.9   23.5
## 2 mtcars cyl       6.19    6      1.79    4      8      4
## 3 mtcars disp     231.   196.   124.   71.1  472   401.
## 4 mtcars hp      147.   123    68.6   52   335   283
## 5 mtcars drat      3.60    3.70   0.535   2.76   4.93   2.17
## 6 mtcars wt       3.22    3.32   0.978   1.51   5.42   3.91
## 7 mtcars qsec     17.8   17.7   1.79  14.5  22.9   8.4
## 8 mtcars vs       0.438    0     0.504    0     1     1
## 9 mtcars am       0.406    0     0.499    0     1     1
## 10 mtcars gear     3.69    4     0.738    3     5     2
## 11 mtcars carb     2.81    2     1.62    1     8     7
##
## $cars
## # A tibble: 2 x 8
##   base variable media mediana desv_std minimo maximo rango
##   <chr> <chr>      <dbl> <dbl>      <dbl> <dbl> <dbl> <dbl>
## 1 cars speed     15.4    15     5.29     4    25    21
## 2 cars dist     43.0    36    25.8     2   120   118
##
## $iris
## # A tibble: 4 x 8
##   base variable      media mediana desv_std minimo maximo rango
##   <chr> <chr>      <dbl> <dbl>      <dbl> <dbl> <dbl> <dbl>
## 1 iris Sepal.Length  5.84    5.8     0.828    4.3    7.9    3.6
## 2 iris Sepal.Width   3.06    3     0.436    2     4.4    2.4
## 3 iris Petal.Length  3.76    4.35    1.77    1     6.9    5.9
## 4 iris Petal.Width   1.20    1.3     0.762    0.1    2.5    2.4
##
## $airquality
## # A tibble: 6 x 8
##   base      variable      media mediana desv_std minimo maximo rango
##   <chr>      <chr>      <dbl> <dbl>      <dbl> <dbl> <dbl> <dbl>
## 1 airquality Ozone     42.1    31.5    33.0     1   168   167
## 2 airquality Solar.R  186.    205    90.1     7   334   327
## 3 airquality Wind       9.96    9.7     3.52    1.7   20.7   19
## 4 airquality Temp      77.9    79     9.47    56    97    41
## 5 airquality Month      6.99    7     1.42    5     9     4
## 6 airquality Day      15.8    16     8.86    1    31    30
```

Manejo de errores en auditoría

```
media_segura <- possibly(function(x) mean(x, na.rm = TRUE), otherwise = NA_real_)

reporte_medias <- map(bases, function(df) {
  map_dbl(df, media_segura)
})
```

```
## Warning in mean.default(x, na.rm = TRUE): argument is not numeric or logical:
## returning NA
```

```
reporte_medias
```

```
## $mtcars
##      mpg      cyl      disp      hp      drat      wt      qsec
## 20.090625  6.187500 230.721875 146.687500  3.596563  3.217250 17.848750
##      vs      am      gear      carb
##  0.437500  0.406250  3.687500  2.812500
##
## $cars
## speed dist
## 15.40 42.98
##
## $iris
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
##      5.843333      3.057333      3.758000      1.199333      NA
##
## $airquality
##      Ozone      Solar.R      Wind      Temp      Month      Day
## 42.129310 185.931507  9.957516 77.882353  6.993464 15.803922
```

Comparación entre pares de variables

```
comparaciones <- tibble(
  base = c("cars", "iris", "iris", "mtcars", "airquality"),
  variable_1 = c("dist", "Petal.Length", "Petal.Width", "hp", "Temp"),
  variable_2 = c("speed", "Sepal.Length", "Sepal.Width", "mpg", "Wind")
)

resultados <- comparaciones %>%
  mutate(
    diferencia_medias = map2_dbl(base, seq_along(base), function(b, i) {
      v1 <- bases[[b]][[variable_1[i]]]
      v2 <- bases[[b]][[variable_2[i]]]
      mean(v1, na.rm = TRUE) - mean(v2, na.rm = TRUE)
    }),
    razon_rangos = map2_dbl(base, seq_along(base), function(b, i) {
      v1 <- bases[[b]][[variable_1[i]]]
      v2 <- bases[[b]][[variable_2[i]]]

      rango_v1 <- max(v1, na.rm = TRUE) - min(v1, na.rm = TRUE)
      rango_v2 <- max(v2, na.rm = TRUE) - min(v2, na.rm = TRUE)

      rango_v1 / rango_v2
    })
  )

resultados
```

```
## # A tibble: 5 x 5
##   base      variable_1 variable_2  diferencia_medias razon_rangos
##   <chr>      <chr>      <chr>          <dbl>          <dbl>
```


## 1 cars	dist	speed	27.6	5.62
## 2 iris	Petal.Length	Sepal.Length	-2.09	1.64
## 3 iris	Petal.Width	Sepal.Width	-1.86	1
## 4 mtcars	hp	mpg	127.	12.0
## 5 airquality	Temp	Wind	67.9	2.16

Reporte final usando *reduce()*

```
t1 <- dimension %>% select(base, filas, columnas)

t2 <- tipos_variaciones %>% select(base, col_num, no_num)

t3 <- tibble(
  base = names(bases),
  faltantes = map_int(bases, ~ sum(is.na(.x)))
)

t4 <- list_rbind(reportes) %>%
  group_by(base) %>%
  summarise(prom_medias = mean(media, na.rm = TRUE), .groups = "drop")

lista_reportes <- list(t1, t2, t3, t4)

reduce(lista_reportes, left_join, by = "base")
```

```
## # A tibble: 4 x 7
##   base      filas columnas col_num no_num faltantes prom_medias
##   <chr>   <int>   <int>   <int> <int>   <int>   <dbl>
## 1 mtcars     32     11     11     0       0     39.6
## 2 cars       50      2      2     0       0     29.2
## 3 iris      150      5      4     1       0      3.46
## 4 airquality 153      6      6     0      44     56.4
```

Preguntas de interpretación

Responde brevemente:

1. ¿Qué base tiene más valores faltantes?

La base *airquality* es quien posee mayor cantidad de valores faltante, y es, de hecho, la única que muestra valores faltantes.

2. ¿Qué base tiene más columnas numéricas?

La base *mtcars* es quien posee mayor cantidad de columnas numéricas, siendo 11 en total.

3. ¿Qué variable tiene el mayor rango en todo el proyecto?

La variable *disp* de la base *mtcars* con un rango de **400.900**.

4. ¿Hay alguna base cuyas columnas sean todas numéricas?

Si, las bases *mtcars*, *cars* y *airquality* son bases que presentan todas sus columnas numéricas.

5. ¿Qué comparación tiene la mayor diferencia de medias?

Las variables *hp* con *mpg* de la base *mtcars* poseen la mayor diferencia de medias en su comparación entre variables.